



Nombre: Peñafiel Jácome Melanie Dayana

Curso: GR1CC

Fecha de entrega: 13 / 05 / 2026

Costos relacionados a los modelos de lenguaje pendiente

- **DIFERENCIA ENTRE ENTRENAMIENTO E INFERENCIA**

- **Inferencia:** proceso mediante el cual un modelo de IA entrenado genera nuevos resultados razonando y haciendo predicciones sobre nuevos datos, clasificando las entradas y aplicando el conocimiento aprendido en tiempo real.
- **Entrenamiento:** es la primera fase de un modelo de IA, puede implicar un proceso de ensayo y error, o un proceso de mostrar al modelo ejemplos de las entradas y salidas deseadas, o ambos.
- La inferencia no puede darse sin entrenamiento.

	ChatGPT	Grok	Gemini	Copilot	Titan
Inferencia / entrenamiento	Entrenamiento: usa alta precisión y grandes lotes. Inferencia: usa baja precisión y es continua.	Entrenamiento: con datos sintéticos y paralelismo extremo. Inferencia: distribuida con baja latencia.	Entrenamiento: multimodal intensivo. Inferencia: optimizada para app's móviles y búsqueda.	Entrenamiento: masivo. Inferencia: optimizada para productividad (código, texto).	Entrenamiento: con alto paralelismo. Inferencia: optimizada para bajo costo y alta velocidad.
Modelo de GPU utilizado	NVIDIA H100, A100	NVIDIA H100	Google TPU v4/v5e	Azure NVIDIA A100/H100 clusters	AWS Trainium
Costo del hardware	Aproximadamente 300 – 600 millones USD	Aproximadamente 200– 500 millones USD	Aproximadamente 10–20 millones USD	Aproximadamente 900 millones – 3 mil millones USD	Aproximadamente 30–100 millones USD
Tiempo de entrenamiento	Varios meses	Varios meses	Fine-tuning continuo	Semanas a meses	Meses

ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE INGENIERÍA EN SISTEMAS
MÉTODOS NUMÉRICOS

Consumo energético (watts)	Entrenamiento: Aproximadamente 7–15 MW (30–90 días) → cientos MWh Inferencia: ~0.01–0.5 Wh por consulta	Entrenamiento: 20–25 MW (~10–25 GWh). Inferencia: MW escala global	Entrenamiento: varios MW (decenas GWh) Inferencia: MW total a escala global	Entrenamiento: MWh por corrida Inferencia: Wh por consulta; uso total en MW	Entrenamiento: MW por pod (MWh totales) Inferencia: MW en despliegue global
-----------------------------------	--	---	--	--	--



ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE INGENIERÍA EN SISTEMAS
MÉTODOS NUMÉRICOS



Fuentes de consulta:

- [Cloudflare](https://www.cloudflare.com/learning/ai/inference-vs-training/). (s.f.). *AI inference vs. training: What is AI inference?* Cloudflare Learning Center.
<https://www.cloudflare.com/learning/ai/inference-vs-training/>